

Nombre:
Almer Gutierrez
Materia:
Electiva 1(Big Data)
Profesora:
Francis Ramirez
Tema:
Carga de la base de datos trasaccional

1. Objetivo

Implementar un proceso de carga de datos (ETL) que lee los archivos CSV del proyecto, valida y transforma la información, y la inserta automáticamente en la base de datos relacional diseñada en la etapa de modelado, garantizando la integridad referencial.

Entorno de ejecución

- Sistema operativo: macOS.
- Base de datos: MySQL 9.3.0 (instalador oficial).
- Lenguaje: Python 3.9.6, con el conector PyMySQL 1.2.3.
- Arquitectura: aplicación monolítica organizada en capas (un solo programa y un solo proceso).

2. Qué pedía la tarea y cómo se cumple

Requisito del enunciado	Cómo se cumple	Dónde
Leer la información desde una fuente de datos	Se leen los 6 CSV con codificación UTF-8.	etl/extraccion.py
Validar la estructura de los datos	Se comprueba que cada archivo exista y traiga las columnas esperadas; si no, se omite ese archivo y se informa.	etl/extraccion.py etl/config.py
Limpiar o transformar	Se quitan espacios sobrantes y se convierten los IDs con prefijo (C007 pasa a 7, P016 a 16).	etl/transformacion.py
Validar registros duplicados	Conjuntos (set) en memoria por ID y por correo, más restricciones UNIQUE en la base.	etl/procesos.py sql/01_esquema.sql
Insertar respetando las relaciones	Se carga primero lo que no depende de nada (fuentes, clientes, productos) y después las opiniones; cada opinión y su subtipo se insertan juntos en un procedimiento almacenado.	etl/procesos.py sql/02_procedimientos.sql
Mostrar procesados, insertados y rechazados	Contadores por archivo y total.	etl/reporte.py
Mostrar un resumen al finalizar	Bloque RESUMEN DE LA CARGA con totales, motivos de rechazo y duración.	etl/reporte.py
Manejo de errores mediante excepciones	Excepciones propias: un registro inválido se rechaza y el proceso continúa; un error grave detiene la carga con un mensaje claro.	etl/excepciones.py

3. Arquitectura

El proyecto es un monolito: un solo programa que se ejecuta como un único proceso. Por dentro se separa por responsabilidades para que cada parte sea fácil de entender y de probar.

Capa	Módulos	Responsabilidad
Entrada	main.py	Lee las opciones de ejecución, configura el registro (log), coordina el proceso y devuelve el código de salida.

Capa	Módulos	Responsabilidad
Negocio	procesos.py validacion.py transformacion.py reporte.py	Valida, limpia, detecta duplicados, comprueba la integridad referencial, define el orden de carga y arma el resumen.
Acceso a datos	repositorio.py extraccion.py	repositorio.py es el único que ejecuta SQL. extraccion.py lee los CSV.
Base de datos	sql/	Tablas, claves, restricciones, procedimientos almacenados y vistas.
Transversal	config.py excepciones.py	Configuración, catálogos permitidos y excepciones propias.

Conexión: el servidor, el puerto, el usuario y el nombre de la base se toman de variables de entorno (DB_HOST, DB_PORT, DB_USER, DB_NAME). La contraseña se toma de DB_PASSWORD; si no existe, se solicita por teclado sin mostrarla en pantalla.

4. Base de datos

4.1 Modelo

Se mantiene el modelo diseñado en la etapa anterior: tres tablas maestras (cliente, producto, fuente_datos), una superclase opinion y tres subtipos (opinion_encuesta, opinion_social, opinion_web), cuyo IdOpinion es a la vez clave primaria y foránea hacia opinion. Se añadió la tabla etl_rechazo para registrar cada fila rechazada.

4.2 Scripts (carpeta sql/)

Archivo	Contenido
00_almacenamiento_fisico.sql	Crea los tablespaces ts_primary y ts_secondary en las carpetas Primary y Secondary.
01_esquema.sql	Crea la base de datos y las tablas, con PK, FK, UNIQUE y CHECK. Asigna cada tabla a su tablespace.
02_procedimientos.sql	sp_registrar_opinion_encuesta, sp_registrar_opinion_social, sp_registrar_opinion_web, sp_opiniones_por_cliente y sp_resumen_carga.
03_vistas.sql	v_opiniones_completas, v_resumen_por_producto y v_resumen_por_origen.
04_consultas_validacion.sql	10 consultas que comprueban la carga y la integridad (ver anexo A).
05_estructura_fisica.sql	Consultas que muestran los archivos físicos, su tamaño y qué tabla está en cada tablespace.

4.3 Estructura de organización de archivos (física)

MySQL no tiene filegroups como SQL Server, así que la organización física se reproduce con tablespaces de InnoDB y con la configuración del servidor:

Carpeta	Contenido
Primary	Tablespace ts_primary (ts_primary.ibd): cliente, producto y fuente_datos.
Secondary	Tablespace ts_secondary (ts_secondary.ibd): opinion, opinion_encuesta, opinion_social, opinion_web y etl_rechazo.
Log	Registro binario (binlog) del servidor, configurado en /etc/my.cnf.

Cada archivo de datos se crea con AUTOEXTEND_SIZE = 64M: inicia en 64 MB y crece de 64 MB en 64 MB. Para que MySQL acepte archivos fuera de su carpeta de datos fue necesario declarar las carpetas Primary y Secondary en la opción innodb_directories de /etc/my.cnf y reiniciar el servidor.

5. Funcionamiento del proceso

5.1 Orden de carga

1. fuente_datos.csv
2. clients.csv
3. products.csv
4. surveys_part1.csv (opiniones de encuesta)
5. social_comments.csv (comentarios de redes sociales)
6. web_reviews.csv (reseñas web)

Los tres primeros son los «padres»: sin ellos las opiniones no podrían apuntar a un cliente, un producto o una fuente.

5.2 Validaciones aplicadas

Validación	Regla
Formato	Fechas en AAAA-MM-DD y no futuras; IDs con el patrón esperado (F###, T####, W####, C###, P###); correo con formato válido.
Campos obligatorios	Los campos requeridos no pueden venir vacíos.
Tipos de datos	Los identificadores, el puntaje y el rating deben ser enteros.
Rangos y catálogos	Puntaje y rating entre 1 y 5; clasificación, canal y tipo de fuente solo con los valores permitidos.
Longitud	No se exceden los tamaños de columna (nombre 100, correo 150, categoría 50).
Registros duplicados	Por ID y por correo, dentro del archivo y contra lo ya cargado.
Integridad referencial	Antes de insertar se comprueba que el cliente y el producto existan; además, las claves foráneas de la base actúan como segunda barrera.
Manejo de errores	ValidacionError (se rechaza la fila y se sigue), EstructuraInvalidaError (se omite el archivo) y ErrorDeCarga (se detiene el proceso).

Cada fila se procesa en su propia transacción: o se inserta completa (la opinión y su subtipo) o no se inserta. Toda fila rechazada se guarda en la tabla etl_rechazo con el archivo, el número de fila, el motivo y el registro original.

6. Decisiones y supuestos

- Solo 6 de las 500 encuestas se cargan. El resto referencia clientes o productos que no existen en los archivos maestros (473 por IdCliente y 21 por IdProducto), así que se rechazan por integridad referencial y quedan registradas en etl_rechazo.
- Los 88 comentarios de redes sociales sin cliente se cargan con IdCliente nulo, como comentarios anónimos.
- Ningún archivo de opiniones trae IdFuente. Es un supuesto de diseño: cada archivo se asocia a la primera fuente de su tipo en fuente_datos (encuestas a F002, redes sociales a F005 y reseñas web a F001).
- Se conserva el ID original del archivo en la columna IdOrigen, para poder rastrear de qué fila proviene cada opinión.
- Los duplicados se detectan por ID y por correo, no por el contenido del comentario.

7. Resultados y evidencias

7.1 Resultado de la ejecución

Ejecución con python main.py --reiniciar (la base se elimina y se recrea desde cero):

Archivo	Leídos	Insertados	Rechazados
fuente_datos.csv	100	100	0
clients.csv	500	500	0
products.csv	200	200	0
surveys_part1.csv	500	6	494
social_comments.csv	200	200	0
web_reviews.csv	200	200	0
TOTAL	1700	1206	494

Motivos de rechazo: Integridad referencial en IdCliente (473) e Integridad referencial en IdProducto (21), ambos en surveys_part1.csv.

7.2 Reejecución sobre la base ya cargada

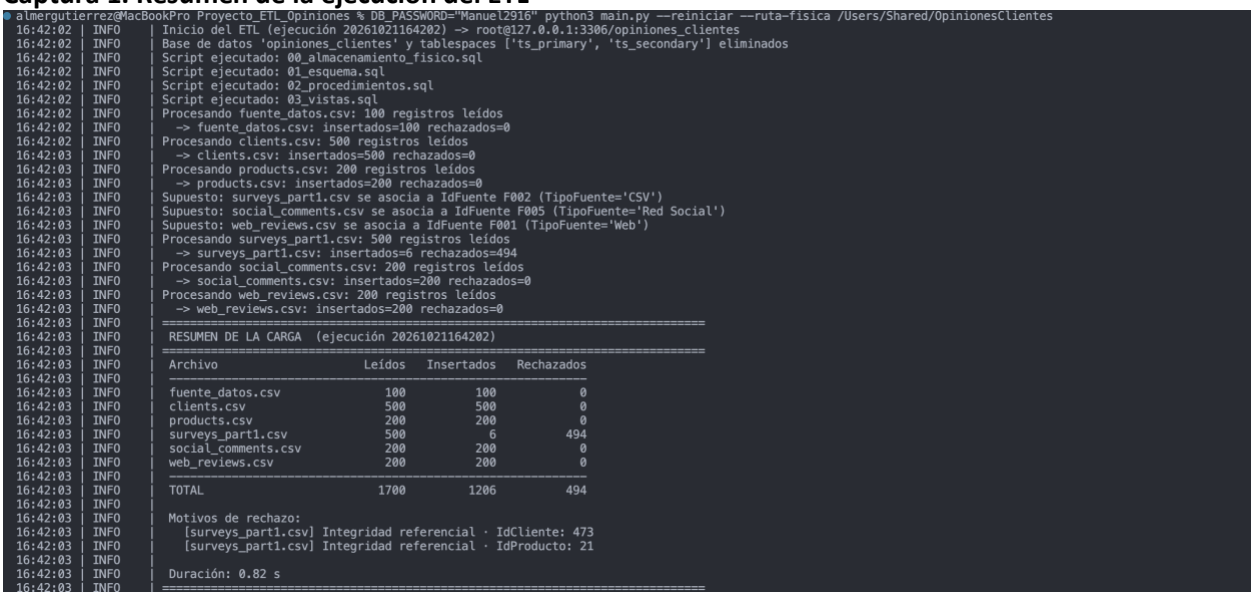
Al ejecutar python main.py sin opciones, el proceso insertó 0 registros y rechazó los 1700: 100 + 500 + 200 + 200 + 200 como registros duplicados, y las 500 encuestas así: 6 duplicadas y 494 por integridad referencial. Esto demuestra que el proceso se puede repetir sin duplicar información.

Las encuestas inválidas no aparecen como duplicadas porque nunca llegaron a la base: el proceso valida primero los duplicados y después la integridad referencial.

7.3 Capturas de pantalla

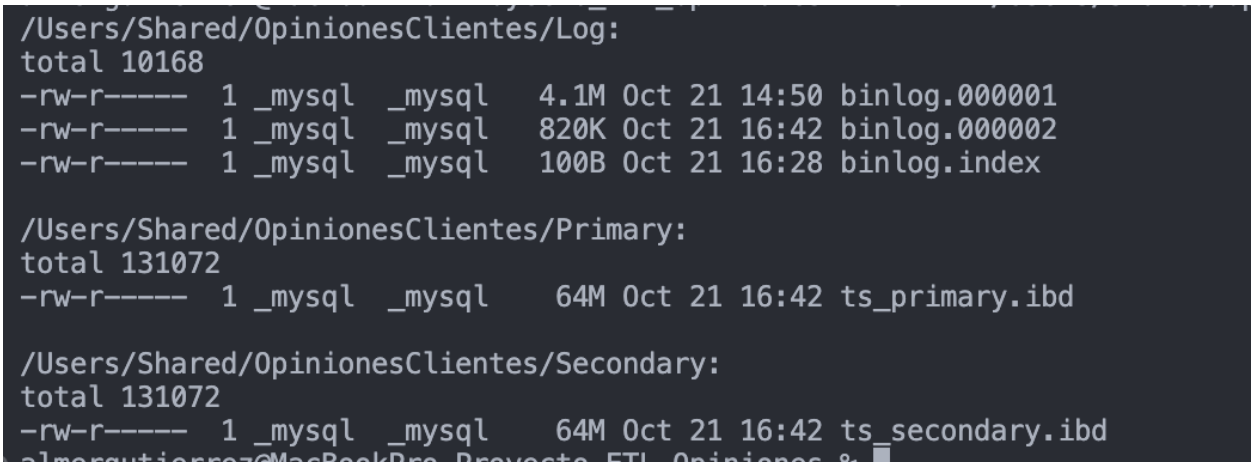
Toma cada captura con Cmd + Shift + 4 y pégala en su recuadro. El comando está indicado dentro de cada uno.

Captura 1. Resumen de la ejecución del ETL



```
almergutierrez@MacBookPro Proyecto_ETL_Opiniones % DB_PASSWORD="Manuel2916" python3 main.py --reiniciar --ruta-fisica /Users/Shared/OpinionesClientes
16:42:02 | INFO     | Inicio del ETL (ejecución 20261021164202) -> root@127.0.0.1:3306/opiniones_clientes
16:42:02 | INFO     | Base de datos 'opiniones_clientes' y tablespaces ['ts_primary', 'ts_secondary'] eliminados
16:42:02 | INFO     | Script ejecutado: 00_almacenamiento_fisico.sql
16:42:02 | INFO     | Script ejecutado: 01_esquema.sql
16:42:02 | INFO     | Script ejecutado: 02_procedimientos.sql
16:42:02 | INFO     | Script ejecutado: 03_vistas.sql
16:42:02 | INFO     | Procesando fuente_datos.csv: 100 registros leídos
16:42:02 | INFO     |   -> fuente_datos.csv: insertados=100 rechazados=0
16:42:02 | INFO     | Procesando clients.csv: 500 registros leídos
16:42:03 | INFO     |   -> clients.csv: insertados=500 rechazados=0
16:42:03 | INFO     | Procesando products.csv: 200 registros leídos
16:42:03 | INFO     |   -> products.csv: insertados=200 rechazados=0
16:42:03 | INFO     | Supuesto: surveys_part1.csv se asocia a IdFuente F002 (TipoFuente='CSV')
16:42:03 | INFO     | Supuesto: social_comments.csv se asocia a IdFuente F005 (TipoFuente='Red Social')
16:42:03 | INFO     | Supuesto: web_reviews.csv se asocia a IdFuente F001 (TipoFuente='Web')
16:42:03 | INFO     | Procesando surveys_part1.csv: 500 registros leídos
16:42:03 | INFO     |   -> surveys_part1.csv: insertados=6 rechazados=494
16:42:03 | INFO     | Procesando social_comments.csv: 200 registros leídos
16:42:03 | INFO     |   -> social_comments.csv: insertados=200 rechazados=0
16:42:03 | INFO     | Procesando web_reviews.csv: 200 registros leídos
16:42:03 | INFO     |   -> web_reviews.csv: insertados=200 rechazados=0
16:42:03 | INFO     | ======================================================================
16:42:03 | INFO     |  RESUMEN DE LA CARGA  (ejecución 20261021164202)
16:42:03 | INFO     | ======================================================================
16:42:03 | INFO     |  Archivo                    Leídos   Insertados   Rechazados
16:42:03 | INFO     |  ----------------------------------------------------------
16:42:03 | INFO     |  fuente_datos.csv              100          100            0
16:42:03 | INFO     |  clients.csv                   500          500            0
16:42:03 | INFO     |  products.csv                  200          200            0
16:42:03 | INFO     |  surveys_part1.csv             500            6          494
16:42:03 | INFO     |  social_comments.csv           200          200            0
16:42:03 | INFO     |  web_reviews.csv               200          200            0
16:42:03 | INFO     |  ----------------------------------------------------------
16:42:03 | INFO     |  TOTAL                        1700         1206          494
16:42:03 | INFO     |
16:42:03 | INFO     |  Motivos de rechazo:
16:42:03 | INFO     |    [surveys_part1.csv] Integridad referencial · IdCliente: 473
16:42:03 | INFO     |    [surveys_part1.csv] Integridad referencial · IdProducto: 21
16:42:03 | INFO     |
16:42:03 | INFO     |  Duración: 0.82 s
16:42:03 | INFO     | ======================================================================
```

Captura 2. Archivos físicos en las carpetas

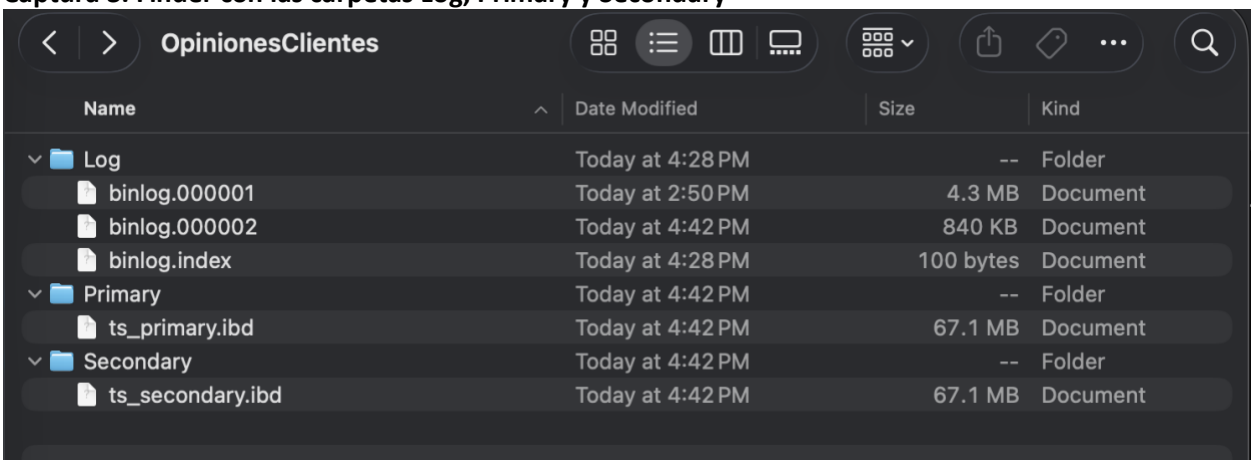


```
/Users/Shared/OpinionesClientes/Log:
total 10168
-rw-r-----  1 _mysql  _mysql   4.1M Oct 21 14:50 binlog.000001
-rw-r-----  1 _mysql  _mysql   820K Oct 21 16:42 binlog.000002
-rw-r-----  1 _mysql  _mysql   100B Oct 21 16:28 binlog.index

/Users/Shared/OpinionesClientes/Primary:
total 131072
-rw-r-----  1 _mysql  _mysql    64M Oct 21 16:42 ts_primary.ibd

/Users/Shared/OpinionesClientes/Secondary:
total 131072
-rw-r-----  1 _mysql  _mysql    64M Oct 21 16:42 ts_secondary.ibd
```

Captura 3. Finder con las carpetas Log, Primary y Secondary



Captura 4. Estructura física en MySQL

```
almergutierrez@MacBookPro Proyecto_ETL_Opiniones % /usr/local/mysql/bin/mysql -u root -p -t < sql/05_estructura_fisica.sql
Enter password:
+-------------+-----------------------------------------------------------+----------+---------------+
| Tablespace  | ArchivoFisico                                             | TamanoMB | CrecimientoMB |
+-------------+-----------------------------------------------------------+----------+---------------+
| ts_primary  | /Users/Shared/OpinionesClientes/Primary/ts_primary.ibd     |     64.0 |          64.0 |
| ts_secondary| /Users/Shared/OpinionesClientes/Secondary/ts_secondary.ibd |     64.0 |          64.0 |
+-------------+-----------------------------------------------------------+----------+---------------+

+-------------------+-------------+
| Tabla             | Tablespace  |
+-------------------+-------------+
| cliente           | ts_primary  |
| fuente_datos      | ts_primary  |
| producto          | ts_primary  |
| etl_rechazo       | ts_secondary|
| opinion           | ts_secondary|
| opinion_encuesta  | ts_secondary|
| opinion_social    | ts_secondary|
| opinion_web       | ts_secondary|
+-------------------+-------------+

+-------------------------------+-----------------------------------------------------------------------------------------------------------+
| Variable_name                 | Value                                                                                                     |
+-------------------------------+-----------------------------------------------------------------------------------------------------------+
| datadir                       | /usr/local/mysql/data/                                                                                    |
| innodb_directories            | /Users/Shared/OpinionesClientes/Primary;/Users/Shared/OpinionesClientes/Secondary                          |
| innodb_log_group_home_dir     | ./                                                                                                        |
| log_bin_basename              | /Users/Shared/OpinionesClientes/Log/binlog                                                                |
| log_error                     | /usr/local/mysql/data/mysqld.local.err                                                                    |
+-------------------------------+-----------------------------------------------------------------------------------------------------------+
```

Captura 5. Consultas de validació

```
+-------------------+-----------+
| Tabla             | Registros |
+-------------------+-----------+
| cliente           |       500 |
| producto          |       200 |
| fuente_datos      |       100 |
| opinion           |       406 |
| opinion_encuesta  |         6 |
| opinion_social    |       200 |
| opinion_web       |       200 |
| etl_rechazo       |       494 |
+-------------------+-----------+

+-----------------------------+
| OpinionesConClienteInexistente |
+-----------------------------+
|                           0 |
+-----------------------------+

+-----------------------------------+
| OpinionesConProductoOFuenteInexistente |
+-----------------------------------+
|                                 0 |
+-----------------------------------+

+--------------------------+
| OpinionesSinSubtipoUnico |
+--------------------------+
|                        0 |
+--------------------------+

+-----------------------------+
| OpinionesConTipoIncoherente |
+-----------------------------+
|                           0 |
+-----------------------------+

+-----------------+
| GruposDuplicados |
+-----------------+
|               0 |
+-----------------+

+---------------------+
| ComentariosAnonimos |
+---------------------+
|                  88 |
+---------------------+

+-------------+-------+----------+---------------+---------------+
| TipoOrigen  | Total | Anonimas | PrimeraFecha  | UltimaFecha   |
+-------------+-------+----------+---------------+---------------+
| Encuesta    |     6 |        0 | 2024-11-24    | 2025-07-02    |
| Social      |   200 |       88 | 2025-06-15    | 2025-09-13    |
| Web         |   200 |        0 | 2024-09-13    | 2025-09-04    |
+-------------+-------+----------+---------------+---------------+

+-----------------+-----------------------+-------------+-----------+
| Archivo         | TipoError             | Campo       | Registros |
+-----------------+-----------------------+-------------+-----------+
| surveys_part1.csv | Integridad referencial | IdCliente   |       473 |
| surveys_part1.csv | Integridad referencial | IdProducto  |        21 |
+-----------------+-----------------------+-------------+-----------+

+-----------+-------------+-----------+------------+-----------------------------------------------------------+-----------+-----------+------------+-------------+-----------+-------------+-----------------+-----------------------+-----------+--------+
| IdOpinion | TipoOrigen  | IdOrigen  | Fecha      | Comentario                                                | IdCliente | Cliente   | IdProducto | Producto    | Categoria | IdFuente    | TipoFuente  | Clasificacion   | PuntajeSatisfaccion   | Canal     | Rating |
+-----------+-------------+-----------+------------+-----------------------------------------------------------+-----------+-----------+------------+-------------+-----------+-------------+-------------+-----------------+-----------------------+-----------+--------+
|       310 | Web         | W0104     | 2024-10-13 | Producto recibido, cumple su función. OK.                 |         7 | Cliente_7 |         14 | Producto_14 | Hogar     | F001        | Web         | NULL            |                  NULL | NULL      |      5 |
|       207 | Web         | W0001     | 2024-10-23 | Producto llegó rápido y funciona perfecto. Muy recomendable. |         7 | Cliente_7 |         16 | Producto_16 | Deportes  | F001        | Web         | NULL            |                  NULL | NULL      |      4 |
|       361 | Web         | W0155     | 2024-12-18 | Pésima atención al cliente. No volvería a comprar.        |         7 | Cliente_7 |         10 | Producto_10 | Electrónica | F001        | Web         | NULL            |                  NULL | NULL      |      1 |
|       276 | Web         | W0070     | 2025-03-14 | Gran relación calidad-precio. Muy recomendable.           |         7 | Cliente_7 |         16 | Producto_16 | Deportes  | F001        | Web         | NULL            |                  NULL | NULL      |      5 |
|       208 | Web         | W0074     | 2025-04-08 | Producto recibido, cumple su función. OK.                 |         7 | Cliente_7 |          5 | Producto_5  | Juguetes  | F001        | Web         | NULL            |                  NULL | NULL      |      4 |
|       395 | Web         | W0189     | 2025-04-10 | Producto llegó rápido y funciona perfecto. Muy recomendable. |         7 | Cliente_7 |         11 | Producto_11 | Hogar     | F001        | Web         | NULL            |                  NULL | NULL      |      4 |
|       291 | Web         | W0085     | 2025-07-06 | Gran relación calidad-precio. Muy recomendable.           |         7 | Cliente_7 |          4 | Producto_4  | Ropa      | F001        | Web         | NULL            |                  NULL | NULL      |      4 |
|        34 | Social      | T0028     | 2025-07-29 | Producto llegó rápido y funciona perfecto                 |         7 | Cliente_7 |          4 | Producto_4  | Ropa      | F005        | Red Social  | NULL            |                  NULL | Instagram |   NULL |
|        65 | Social      | T0059     | 2025-08-03 | Muy satisfecho con la compra, lo recomiendo               |         7 | Cliente_7 |         11 | Producto_11 | Hogar     | F005        | Red Social  | NULL            |                  NULL | Facebook  |   NULL |
+-----------+-------------+-----------+------------+-----------------------------------------------------------+-----------+-----------+------------+-------------+-----------+-------------+-------------+-----------------+-----------------------+-----------+--------+
```

Captura 6. Tablas pobladas



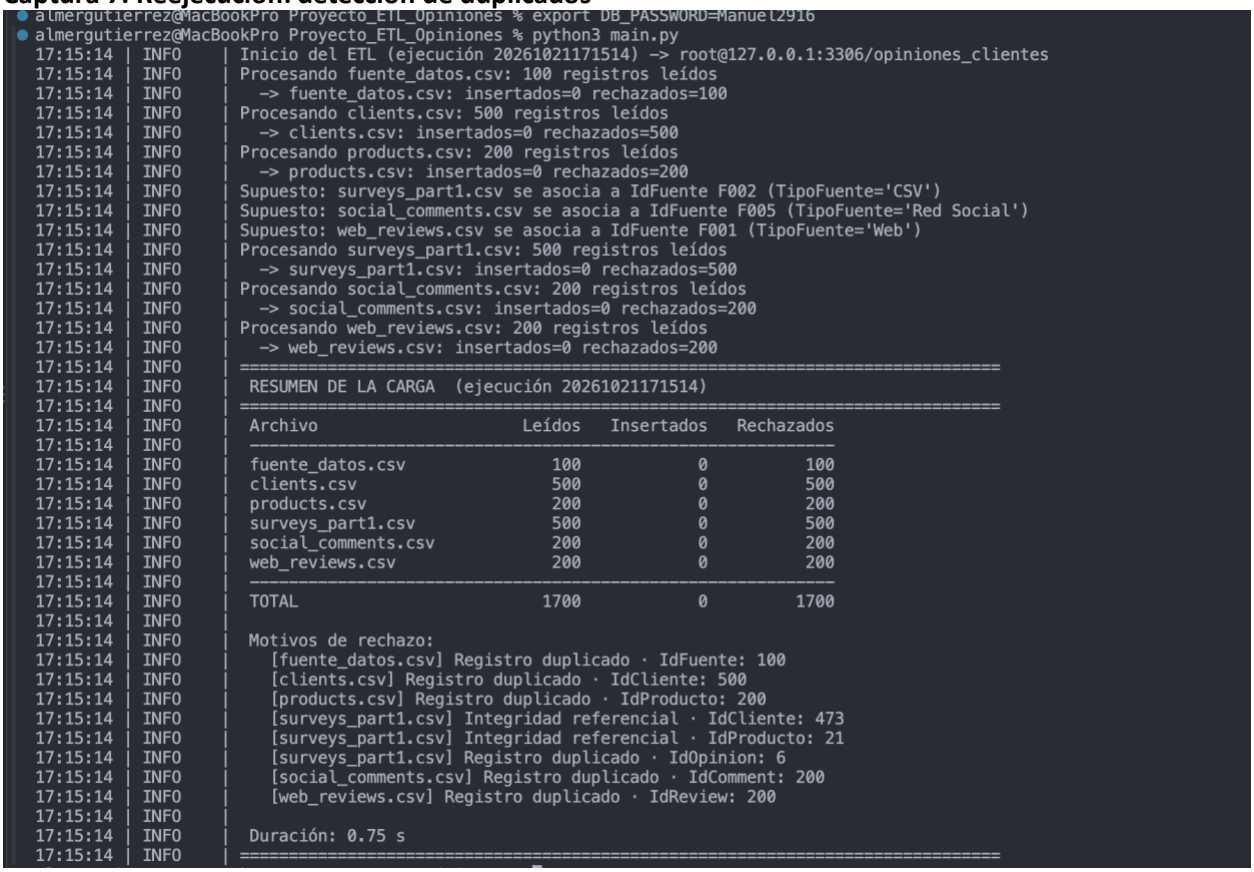
IdCliente	Nombre	Email
1	Cliente_1	cliente1@mail.com
2	Cliente_2	cliente2@mail.com
3	Cliente_3	cliente3@mail.com
4	Cliente_4	cliente4@mail.com
5	Cliente_5	cliente5@mail.com

IdOpinion	IdOrigen	IdCliente	IdProducto	IdFuente	Fecha	Comentario	TipoOrigen
1	124	382	131	F002	2024-12-19	El producto cumple su función, nada especial.	Encuesta
2	150	203	97	F002	2025-08-03	No era lo que esperaba, muy decepcionado.	Encuesta
3	206	150	148	F002	2025-03-08	El servicio fue rápido y eficiente, entrega muy satisfecho.	Encuesta
4	221	353	124	F002	2025-03-01	El servicio fue lento y el soporte no resolvió mi problema.	Encuesta
5	204	157	57	F002	2024-11-24	El envío fue normal, dentro del tiempo esperado.	Encuesta

IdOpinion	Rating
207	4
208	3
209	5
210	4
211	1

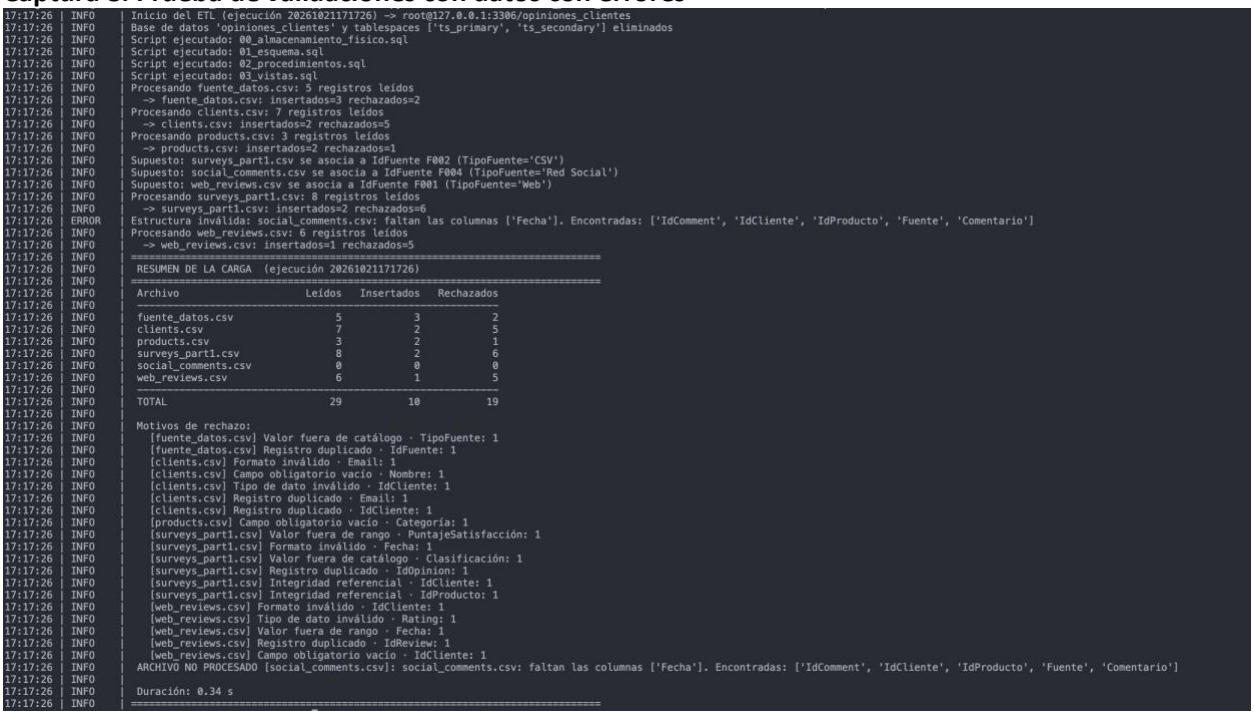
IdRechazo	IdEjecucion	Archivo	Fila	TipoError	Campo	Detalle	Registro	FechaRegistro
1	20261021164202	surveys_part1.csv	2	Integridad referencial	IdCliente	cliente 8537 no existe en la tabla cliente	{"IdOpinion": "1", "IdCliente": "8537", "IdProducto": "360", "Fecha": "2025-07-15", "Comentario": "El producto está bien, pero esperaba un poco más de calidad.", "Clasificación": "Neutra", "PuntajeSatisfacción": "3", "Fuente": "EncuestaInterna"}	2026-10-21 16:42:03
2	20261021164202	surveys_part1.csv	3	Integridad referencial	IdCliente	cliente 2721 no existe en la tabla cliente	{"IdOpinion": "2", "IdCliente": "2721", "IdProducto": "667", "Fecha": "2024-12-07", "Comentario": "No malo ni excelente, simplemente regular.", "Clasificación": "Neutra", "PuntajeSatisfacción": "3", "Fuente": "EncuestaInterna"}	2026-10-21 16:42:03
3	20261021164202	surveys_part1.csv	4	Integridad referencial	IdCliente	cliente 8424 no existe en la tabla cliente	{"IdOpinion": "3", "IdCliente": "8424", "IdProducto": "853", "Fecha": "2025-06-20", "Comentario": "Mala calidad, no lo recomiendo para nada.", "Clasificación": "Negativa", "PuntajeSatisfacción": "1", "Fuente": "EncuestaInterna"}	2026-10-21 16:42:03
4	20261021164202	surveys_part1.csv	5	Integridad referencial	IdCliente	cliente 8672 no existe en la tabla cliente	{"IdOpinion": "4", "IdCliente": "8672", "IdProducto": "961", "Fecha": "2025-08-17", "Comentario": "El producto está bien, pero esperaba un poco más de calidad.", "Clasificación": "Neutra", "PuntajeSatisfacción": "3", "Fuente": "EncuestaInterna"}	2026-10-21 16:42:03
5	20261021164202	surveys_part1.csv	6	Integridad referencial	IdCliente	cliente 8018 no existe en la tabla cliente	{"IdOpinion": "5", "IdCliente": "8018", "IdProducto": "687", "Fecha": "2024-10-22", "Comentario": "El producto llegó en perfecto estado y antes de tiempo.", "Clasificación": "Positiva", "PuntajeSatisfacción": "5", "Fuente": "EncuestaInterna"}	2026-10-21 16:42:03

Captura 7. Reejecución: detección de duplicados



```
almergutierrez@MacBookPro Proyecto_ETL_Opiniones % export DB_PASSWORD=Manuel2916
almergutierrez@MacBookPro Proyecto_ETL_Opiniones % python3 main.py
17:15:14 | INFO     | Inicio del ETL (ejecución 20261021171514) -> root@127.0.0.1:3306/opiniones_clientes
17:15:14 | INFO     | Procesando fuente_datos.csv: 100 registros leídos
17:15:14 | INFO     |   -> fuente_datos.csv: insertados=0 rechazados=100
17:15:14 | INFO     | Procesando clients.csv: 500 registros leídos
17:15:14 | INFO     |   -> clients.csv: insertados=0 rechazados=500
17:15:14 | INFO     | Procesando products.csv: 200 registros leídos
17:15:14 | INFO     |   -> products.csv: insertados=0 rechazados=200
17:15:14 | INFO     | Supuesto: surveys_part1.csv se asocia a IdFuente F002 (TipoFuente='CSV')
17:15:14 | INFO     | Supuesto: social_comments.csv se asocia a IdFuente F005 (TipoFuente='Red Social')
17:15:14 | INFO     | Supuesto: web_reviews.csv se asocia a IdFuente F001 (TipoFuente='Web')
17:15:14 | INFO     | Procesando surveys_part1.csv: 500 registros leídos
17:15:14 | INFO     |   -> surveys_part1.csv: insertados=0 rechazados=500
17:15:14 | INFO     | Procesando social_comments.csv: 200 registros leídos
17:15:14 | INFO     |   -> social_comments.csv: insertados=0 rechazados=200
17:15:14 | INFO     | Procesando web_reviews.csv: 200 registros leídos
17:15:14 | INFO     |   -> web_reviews.csv: insertados=0 rechazados=200
17:15:14 | INFO     | ================================================================================
17:15:14 | INFO     |  RESUMEN DE LA CARGA  (ejecución 20261021171514)
17:15:14 | INFO     | ================================================================================
17:15:14 | INFO     |  Archivo                    Leídos   Insertados   Rechazados
17:15:14 | INFO     |  ------------------------------------------------------------
17:15:14 | INFO     |  fuente_datos.csv              100            0          100
17:15:14 | INFO     |  clients.csv                   500            0          500
17:15:14 | INFO     |  products.csv                  200            0          200
17:15:14 | INFO     |  surveys_part1.csv             500            0          500
17:15:14 | INFO     |  social_comments.csv           200            0          200
17:15:14 | INFO     |  web_reviews.csv               200            0          200
17:15:14 | INFO     |  ------------------------------------------------------------
17:15:14 | INFO     |  TOTAL                        1700            0         1700
17:15:14 | INFO     |
17:15:14 | INFO     |  Motivos de rechazo:
17:15:14 | INFO     |    [fuente_datos.csv] Registro duplicado · IdFuente: 100
17:15:14 | INFO     |    [clients.csv] Registro duplicado · IdCliente: 500
17:15:14 | INFO     |    [products.csv] Registro duplicado · IdProducto: 200
17:15:14 | INFO     |    [surveys_part1.csv] Integridad referencial · IdCliente: 473
17:15:14 | INFO     |    [surveys_part1.csv] Integridad referencial · IdProducto: 21
17:15:14 | INFO     |    [surveys_part1.csv] Registro duplicado · IdOpinion: 6
17:15:14 | INFO     |    [social_comments.csv] Registro duplicado · IdComment: 200
17:15:14 | INFO     |    [web_reviews.csv] Registro duplicado · IdReview: 200
17:15:14 | INFO     |
17:15:14 | INFO     |  Duración: 0.75 s
17:15:14 | INFO     | ================================================================================
```

Captura 8. Prueba de validaciones con datos con errores



8. Consultas de validación

El archivo sql/04_consultas_validacion.sql contiene 10 consultas (el enunciado pide al menos 5). Cada una indica lo que demuestra y el resultado que debe aparecer; el SQL completo está en el anexo A.

N.º	Qué demuestra	Resultado esperado
1	Cuántos registros hay en cada tabla (procedimiento almacenado).	Tabla de 8 filas: cliente 500, producto 200, fuente_datos 100, opinion 406, opinion_encuesta 6, opinion_social 200, opinion_web 200, etl_rechazo 494.
2	Ninguna opinión apunta a un cliente que no existe.	OpinionesConClienteInexistente = 0
3	Ninguna opinión apunta a un producto o fuente que no existe.	OpinionesConProductoOFuenteInexistente = 0
4	Cada opinión tiene exactamente un subtipo (especialización total y disjunta).	OpinionesSinSubtipoUnico = 0
5	El campo TipoOrigen coincide con la subtabla donde está el detalle.	OpinionesConTipoIncoherente = 0
6	No hay opiniones duplicadas por (TipoOrigen, IdOrigen).	GruposDuplicados = 0
7	Los comentarios anónimos se cargaron con IdCliente nulo.	ComentariosAnonimos = 88
8	Lo insertado por origen cuadra con lo leído de los archivos.	Encuesta 6, Social 200, Web 200 (anónimas: 0, 88 y 0).
9	La bitácora registra cada rechazo con su motivo.	surveys_part1.csv: Integridad referencial en IdCliente = 473 e IdProducto = 21.

N.º	Qué demuestra	Resultado esperado
10	La vista y el procedimiento devuelven datos integrados de varias tablas.	Listado de las opiniones del cliente 7, con producto, categoría, fuente y el dato específico de cada tipo.

Los resultados esperados corresponden a la carga limpia (python main.py --reiniciar). Si se ejecuta la reejecución antes, la tabla etl_rechazo acumula filas y los conteos de las consultas 1 y 9 cambian.

9. Cómo ejecutar el proyecto (macOS)

1. Comprobar que MySQL está encendido: /usr/local/mysql/bin/mysqladmin -u root -p ping
2. Entrar a la carpeta del proyecto y activar el entorno: source .venv/bin/activate
3. Definir la conexión: export DB_HOST=127.0.0.1 DB_PORT=3306 DB_USER=root
4. Ejecutar: python main.py --reiniciar --ruta-fisica /Users/Shared/OpinionesClientes (pide la contraseña)
5. Ejecutar las consultas de las secciones 7 y 8 y tomar las capturas.

--reiniciar elimina y recrea la base opiniones_clientes. Los datos se regeneran desde los CSV.

10. Estructura de archivos de la entrega

```
Proyecto_ETL_Opiniones/
├── main.py                    punto de entrada
├── requirements.txt           dependencias (PyMySQL, cryptography)
├── README.md                  instrucciones de uso
├── etl/                       módulos de la aplicación
├── sql/                       scripts 00 a 05
├── config/                    ejemplo de configuración del servidor
├── data/                      CSV originales
├── data_prueba_errores/       CSV con errores para probar las validaciones
└── evidencias/                capturas y salidas de la ejecución
```

11. Lista de verificación antes de entregar

Hecho	Elemento
☐	Capturas 1 a 8 pegadas en la sección 7.3 (la 8 es opcional).
☐	Nombre del estudiante, docente y fecha completados en la portada.
☐	Carpeta evidencias/ con tus propias capturas (no las de referencia).
☐	Carpeta del proyecto comprimida sin .venv ni __pycache__.
☐	Este informe guardado en el proyecto y entregado junto con él.

Anexo A. Consultas de validación (SQL)

1) Registros cargados por tabla (procedimiento almacenado)

```
CALL sp_resumen_carga();
```

2) Integridad referencial: opiniones con cliente informado que no existe en cliente (esperado: 0 filas)

```
SELECT COUNT(*) AS OpinionesConClienteInexistente
FROM opinion o
LEFT JOIN cliente c ON c.IdCliente = o.IdCliente
WHERE o.IdCliente IS NOT NULL AND c.IdCliente IS NULL;
```

3) Integridad referencial: opiniones cuyo producto o fuente no existe (esperado: 0 filas)

```
SELECT COUNT(*) AS OpinionesConProductoOFuenteInexistente
FROM opinion o
LEFT JOIN producto p     ON p.IdProducto = o.IdProducto
LEFT JOIN fuente_datos f ON f.IdFuente   = o.IdFuente
WHERE p.IdProducto IS NULL OR f.IdFuente IS NULL;
```

4) Especialización total y disjunta: cada opinión tiene EXACTAMENTE un subtipo (esperado: 0 filas)

```
SELECT COUNT(*) AS OpinionesSinSubtipoUnico
FROM (
    SELECT o.IdOpinion,
           (oe.IdOpinion IS NOT NULL) + (os.IdOpinion IS NOT NULL) + (ow.IdOpinion IS NOT NULL) AS
Subtipos
    FROM opinion o
    LEFT JOIN opinion_encuesta oe ON oe.IdOpinion = o.IdOpinion
    LEFT JOIN opinion_social   os ON os.IdOpinion = o.IdOpinion
    LEFT JOIN opinion_web      ow ON ow.IdOpinion = o.IdOpinion
) t
WHERE Subtipos <> 1;
```

5) Coherencia: TipoOrigen coincide con la subtabla donde está el detalle (esperado: 0 filas)

```
SELECT COUNT(*) AS OpinionesConTipoIncoherente
FROM opinion o
LEFT JOIN opinion_encuesta oe ON oe.IdOpinion = o.IdOpinion
LEFT JOIN opinion_social   os ON os.IdOpinion = o.IdOpinion
LEFT JOIN opinion_web      ow ON ow.IdOpinion = o.IdOpinion
WHERE (o.TipoOrigen = 'Encuesta' AND oe.IdOpinion IS NULL)
   OR (o.TipoOrigen = 'Social'   AND os.IdOpinion IS NULL)
   OR (o.TipoOrigen = 'Web'      AND ow.IdOpinion IS NULL);
```

6) Duplicados: no existe más de una opinión con el mismo (TipoOrigen, IdOrigen) (esperado: 0 filas)

```
SELECT COUNT(*) AS GruposDuplicados
FROM (SELECT 1 FROM opinion GROUP BY TipoOrigen, IdOrigen HAVING COUNT(*) > 1) d;
```

7) Transformación de IDs y anónimos: comentarios sociales sin cliente (esperado: 88 en este dataset)

```
SELECT COUNT(*) AS ComentariosAnonimos FROM opinion WHERE TipoOrigen = 'Social' AND IdCliente IS
NULL;
```

8) Cuadre archivo vs base: insertadas por origen frente a lo leído (6 + 200 + 200)

```
SELECT * FROM v_resumen_por_origen;
```

9) Rechazos registrados en la bitácora, por archivo y motivo

```
SELECT Archivo, TipoError, Campo, COUNT(*) AS Registros
FROM etl_rechazo WHERE IdEjecucion = (SELECT MIN(IdEjecucion) FROM etl_rechazo)
GROUP BY Archivo, TipoError, Campo ORDER BY Archivo;
```

10) Vista de negocio: opiniones completas de un cliente (procedimiento + vista)

```
CALL sp_opiniones_por_cliente(7);
```